

Boosting

Leonardo Uchoa Pedreira

RA: 156231

and

Victor Freguglia Souza

RA: 137784

20 de Novembro de 2018

Resumo

The text of your abstract. 200 or fewer words.

Keywords: Quando for a versão final., Tirar esse campo na .tex;

1 Introdução

Boosting é o nome dado a um tipo de algoritmo que, assim como outros métodos em Machine Learning como Bagging e Florestas Aleatórias, busca combinar um grande número de preditores com baixo poder de predição para compor um bom preditor. O conceito é fundamentado das ideias apresentadas em Kearns (1988) e Schapire (1990).

Diferentemente dos outros métodos citados, onde os preditores fracos que serão combinados são criados de maneira independente (e aleatória devido ao processo de bootstrap), no método de Boosting os preditores fracos são criados de maneira a melhorar o desempenho em regiões com alta taxa de erro.

O algoritmo AdaBoost (de *Adaptive Boosting*), apresentado pela primeira vez em Freund & Schapire (1997), é um dos exemplos mais clássicos de algoritmo de boosting para o problema de classificação binária. Nele, a cada passo m , um novo classificador G_m é ajustado com base em uma versão ponderada do conjunto de dados original, na qual o peso de cada observação depende do desempenho do classificador anterior: pontos classificados de maneira errada recebem peso maior, assim, têm uma chance maior de serem corrigidos pelos classificadores ajustados na próxima iteração. O Algoritmo 1 apresenta a descrição completa do AdaBoost.

Note que o classificador a ser usado não precisa ser nenhum específico e, portanto, se comporta como um parâmetro a ser escolhido por um processo de regulação (tuning) do problema, embora o mais comum, pela grande flexibilidade seja a árvore de classificação e regressão.

Falar que precisa ainda pensar nos casos de regressão e classificação multivariada. Citar a extensão multivariada do adaBoost Hastie et al. (2009). Falar que vai focar só no Gradient Boosting porque é mais geral. Citar que os algoritmos diferem principalmente em como faz reweighting dos dados.

2 Metodologia

Do ponto de vista da teoria de decisão, escolher o melhor preditor significa escolher a função G^* que minimiza a função risco, definida como o valor esperado da função de perda $L(\cdot, \cdot)$.

início

Inicie todos pesos $w_i = 1/N$;

para $m = 1, \dots, M$ **faça**

1. Ajuste um classificador $G_m(x)$;

2. Calcular

$$\text{err}_m = \frac{\sum_{i=1}^N w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i};$$

3. Calcular $\alpha_m = \log\left(\frac{1-\text{err}_m}{\text{err}_m}\right)$;

4. Atualizar $w_i \leftarrow w_i \exp(\alpha_m I(y_i \neq G_m(x_i)))$, $i = 1, \dots, N$;

fim

Defina o classificador final como

$$G(x) = \text{sign}\left(\sum_{m=1}^M \alpha_m I(G_m(x) = k)\right).$$

fim

Algoritmo 1: Algoritmo AdaBoost apresentado em Friedman et al. (2001). Aqui, as classes do problema de classificação são representadas pelos valores -1 e 1.

$$G^* = \arg \min_G \mathbb{E}L(Y, G(\mathbf{X})) \quad (1)$$

2.1 Gradient Boosting

- Citar o xgboost, caret.

2.2 PCA Whitening

3 Dados

Conjunto de dados MNIST.

- Mostrar alguns números

4 Aplicação

- Ajuste
- Comparar com Random Forest, nnet, pca-whitened

5 Discussão

- Não sei o que entra em discussão/conclusão?

Referências

- Freund, Y. & Schapire, R. E. (1997), ‘A decision-theoretic generalization of on-line learning and an application to boosting’, *Journal of computer and system sciences* **55**(1), 119–139.
- Friedman, J., Hastie, T. & Tibshirani, R. (2001), *The elements of statistical learning*, Vol. 1, Springer series in statistics New York, NY, USA:.
- Hastie, T., Rosset, S., Zhu, J. & Zou, H. (2009), ‘Multi-class adaboost’, *Statistics and its Interface* **2**(3), 349–360.
- Kearns, M. (1988), ‘Thoughts on hypothesis boosting’, *Unpublished manuscript* **45**, 105.
- Schapire, R. E. (1990), ‘The strenght of weak learnability’, *Machine Learning* **5**, 197–227.